



2ª série

Inteligência Artificial

Conceitos Fundamentais da Inteligência Artificial

Rildo Oliveira



29/02/2024

ROTEIRO DE AULA

OBJETO DO CONHECIMENTO: Conceitos Fundamentais da Inteligência Artificial

HABILIDADE: Levantar e testar hipóteses para resolver problemas do cotidiano pessoal, da escola e do trabalho, utilizando procedimentos e linguagens adequados à investigação científica.

OBJETIVOS:

- Compreender os princípios básicos da IA, como aprendizado de máquina e redes neurais.
- Identificar as principais áreas de aplicação da IA

DA TEORIA À PRÁTICA: Uso de imagens, texto e conceitos para um melhor entendimento do tema abordado.


Pasta Compartilhada e Grupo



<https://github.com/rildexter/2ST-IA-2024>

Princípios Básicos Da Inteligência Artificial

A Inteligência Artificial (IA) é um campo da ciência da computação que se concentra no desenvolvimento de sistemas capazes de realizar tarefas que normalmente requerem inteligência humana.



Princípios Básicos Da Inteligência Artificial

Dois princípios fundamentais da IA são:

- Aprendizado de Máquina.
- Redes Neurais.


Aprendizado De Máquina E Redes Neurais

O **Aprendizado de Máquina** é uma subárea da IA que permite aos computadores aprenderem a partir de dados, sem serem explicitamente programados.

As **Redes Neurais** são um modelo computacional inspirado no funcionamento do cérebro humano, composto por neurônios interconectados.

Introdução ao Aprendizado de Máquina


O aprendizado de máquina é um ramo da inteligência artificial que se concentra no desenvolvimento de algoritmos que permitem aos computadores aprenderem a partir de dados.



Introdução ao Aprendizado de Máquina




Ele permite que os sistemas automatizem tarefas sem a necessidade de serem explicitamente programados para cada ação.

O aprendizado de máquina é amplamente utilizado em áreas como reconhecimento de padrões, processamento de linguagem natural, visão computacional e muito mais.



Introdução ao Aprendizado de Máquina


No aprendizado de máquina, os algoritmos são treinados com conjuntos de dados para encontrar padrões nos dados e fazer previsões ou tomar decisões.



Um algoritmo pode realmente aprender?

Reconhecer emoções!

Figura 1 – Expressão facial: alegria



alegria


- ① pés de galinha
- ② maçãs do rosto salientes
- ③ olhos em "órbita"

Fonte: Ekman, 2011

Um algoritmo pode realmente aprender?

No reconhecimento de emoções em imagens faciais, os algoritmos podem ser treinados com conjuntos de dados rotulados, onde cada imagem é associada a uma emoção específica (como felicidade, tristeza, raiva, etc.).

Figura 2 – Expressão facial: tristeza




Fonte: Ekman, 2011

Um algoritmo pode realmente aprender?

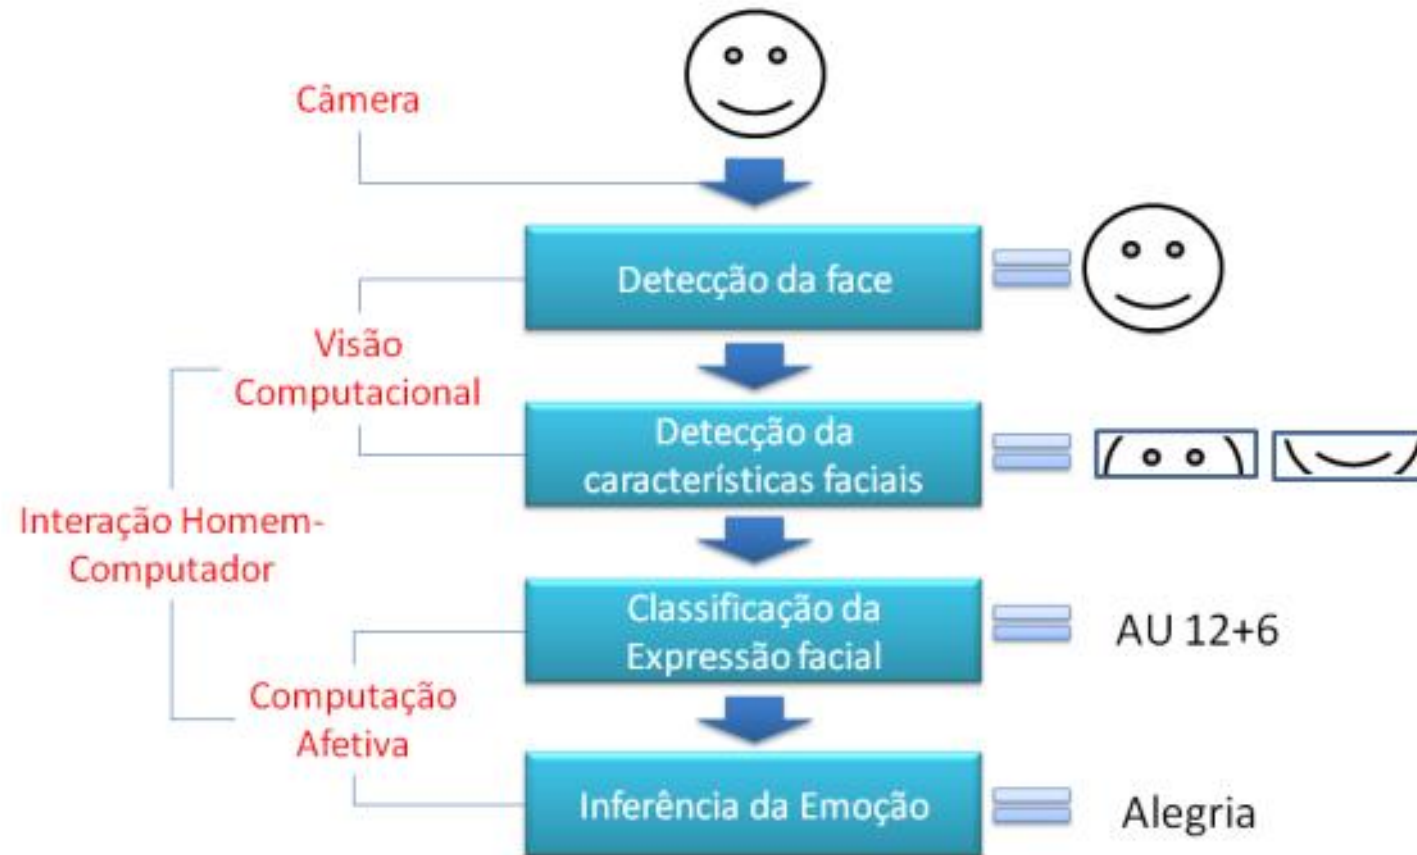
Com técnicas avançadas de aprendizado de máquina, como redes neurais convolucionais, é possível extrair características das expressões faciais e aprender padrões que correspondem a diferentes emoções.

Figura 3 – Expressão facial: raiva



Fonte: Ekman, 2011

Como a IA detecta emoções




Fonte: Jaques e Oliveira, 2008



Pré-processamento de Dados

O pré-processamento de dados envolve a preparação e limpeza dos dados antes de alimentá-los aos algoritmos de aprendizado. Isso inclui tarefas como remoção de valores ausentes, normalização de dados, codificação de variáveis categóricas e seleção de características relevantes.



Pré-processamento de Dados

Um pré-processamento adequado dos dados pode melhorar significativamente o desempenho dos modelos de aprendizado de máquina.



Algoritmos de Aprendizado Supervisionado

Os algoritmos de aprendizado supervisionado são treinados com pares de entrada e saída conhecidos. Isso inclui algoritmos como Regressão Linear, que modela relações lineares, e Máquinas de Vetores de Suporte, que encontram fronteiras de decisão ótimas para classificação.



Problemas Comuns em Aprendizado Supervisionado

Desafios como overfitting, onde o modelo se adapta demais aos dados de treinamento, e underfitting, onde o modelo não captura as complexidades dos dados, são comuns. Além disso, a importância de conjuntos de validação na busca por modelos robustos.

Overfitting e Underfitting: Causas e Soluções

Overfitting e underfitting são problemas comuns em aprendizado de máquina que ocorrem quando o modelo é muito complexo ou muito simples em relação aos dados.

O overfitting ocorre quando o modelo se ajusta demais aos dados de treinamento e falha em generalizar para novos dados.

Overfitting e Underfitting: Causas e Soluções

Exemplo: se oferecermos a um sistema uma grande quantidade de imagens de gatos para que ele reconheça o que é um gato, pelo excesso de imagem ele irá usar a comparação de imagens e não buscará as características dos felinos



Overfitting e Underfitting

O underfitting ocorre quando o modelo é muito simplificado e não consegue capturar a complexidade dos dados.

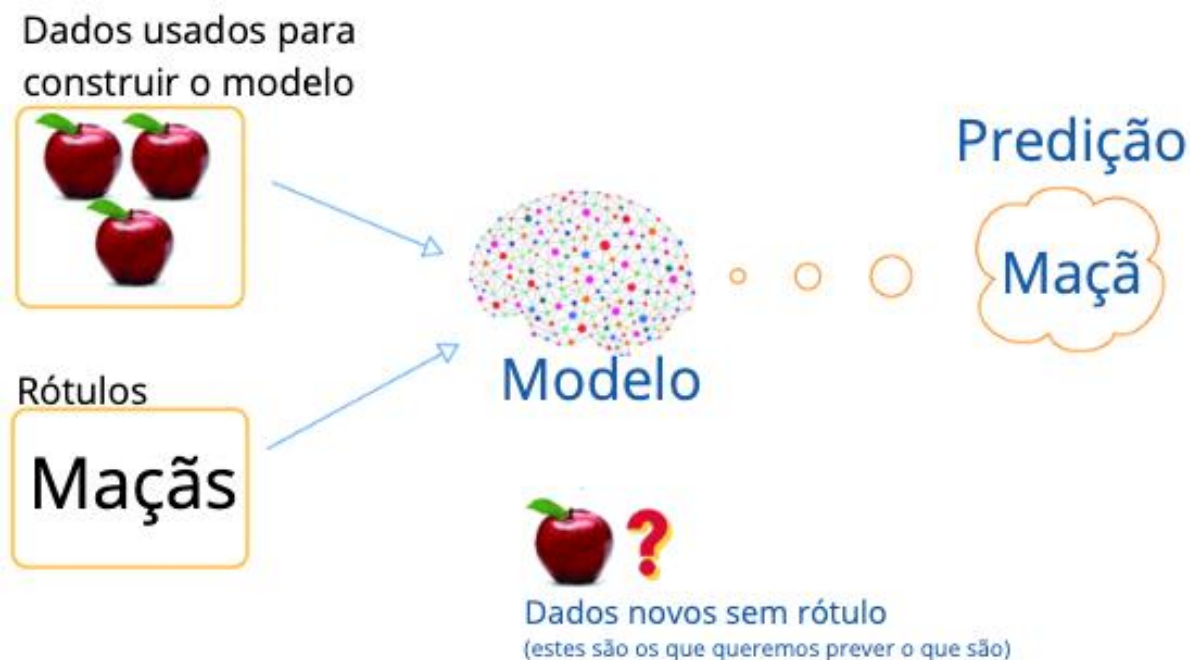
Um sistema tenta prever se um e-mail é spam ou não com base em várias características.

Se você usar um modelo de aprendizado muito simples o modelo pode não ser capaz de capturar a complexidade dos dados e seu resultado será ruim.



Algoritmos de Aprendizado Não Supervisionado

No aprendizado não supervisionado, algoritmos como o K-means são utilizados para agrupar dados sem rótulos. Já a Análise de Componentes Principais (PCA) reduz a dimensionalidade, destacando as características mais importantes dos dados.



Aplicações Práticas do Aprendizado Não Supervisionado

O aprendizado não supervisionado é aplicado em diversas áreas, desde segmentação de mercado até organização automática de dados. Esses algoritmos permitem descobrir padrões e estruturas ocultas nos dados.



Aprendizado por Reforço

No aprendizado por reforço, um agente aprende a realizar ações em um ambiente para maximizar recompensas. Isso é comumente usado em jogos, robótica e otimização de sistemas complexos.



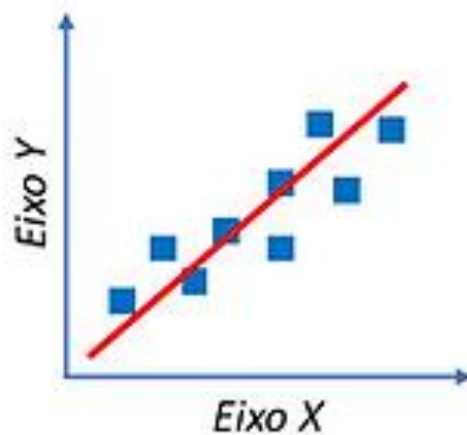
Desafios em Aprendizado por Reforço

O aprendizado por reforço enfrenta desafios como a maldição da dimensionalidade, onde o espaço de ações se torna vasto, e o dilema exploração versus exploração, onde o agente deve equilibrar a busca por recompensas imediatas e a exploração de novas ações.




TIPOS DE APRENDIZADO DE MACHINE LEARNING


Aprendizado
Supervisionado



Aprendizado
Não Supervisionado




Aprendizado
por Reforço



Aprendizado Profundo (Deep Learning)


O aprendizado profundo, também conhecido como deep learning, é uma subárea do aprendizado de máquina que utiliza redes neurais profundas para aprender representações de dados.

Ele é capaz de lidar com grandes volumes de dados e extrair características complexas de maneira automática.



Aprendizado Profundo (Deep Learning)

O aprendizado profundo tem sido aplicado com sucesso em diversas áreas, como visão computacional, processamento de linguagem natural, reconhecimento de fala, reconhecimento de imagem e muito mais.



Redes Neurais Artificiais

As redes neurais artificiais são modelos computacionais inspirados no funcionamento do cérebro humano. Elas são compostas por neurônios artificiais interconectados, organizados em camadas, e são capazes de aprender a partir de dados.




Redes Neurais Artificiais

As redes neurais artificiais são amplamente utilizadas em aprendizado de máquina, reconhecimento de padrões, processamento de linguagem natural, visão computacional e muito mais.



Redes Neurais Artificiais

O treinamento de redes neurais artificiais envolve a apresentação de exemplos de entrada juntamente com as saídas desejadas, e ajuste dos pesos das conexões entre os neurônios para minimizar uma função de custo.



Dica de Vídeo

O que é Machine Learning (Aprendizado de Máquina)?

Por que o Machine Learning tem sido tão importante no mundo da inteligência artificial.



Referências Bibliográficas

1. Russell, S.; Norvig, P. (2016). "Artificial Intelligence: A Modern Approach". Pearson.
2. Nilsson, N. J. (2009). "The Quest for Artificial Intelligence: A History of Ideas and Achievements". Cambridge University Press.
3. McCarthy, J.; Minsky, M. L.; Rochester, N.; Shannon, C. E. (1955). "A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence". AI Magazine, 27(4).
4. Kurzweil, R. (2005). "The Singularity Is Near: When Humans Transcend Biology". Viking Adult.



ATÉ A PRÓXIMA AULA!