

2ª série

Inteligência Artificial

Algoritmos de Recomendação

Rildo Oliveira



19/09/2024

ROTEIRO DE AULA

OBJETO DO CONHECIMENTO: Algoritmos de Recomendação

HABILIDADE:

PCRPO3 - Identificar, entender e explicar em que situações o computador pode ou não ser utilizado para solucionar um problema.

EF05HI06 - Comparar o uso de diferentes linguagens e tecnologias no processo de comunicação e avaliar os significados sociais, políticos e culturais atribuídos a elas.

OBJETIVOS:

- Estudar como os algoritmos de recomendação funcionam e são aplicados em plataformas como Netflix e Amazon.
- Implementar um algoritmo simples de recomendação utilizando um conjunto de dados.

DA TEORIA À PRÁTICA: Uso de imagens, texto e conceitos para um melhor entendimento do tema abordado.

✓ Aulas gravadas e ao vivo

✓ Guia de estudos com IA

✓ Monitorias em tempo real

✓ Correção de redação

✓ Resumos de aulas e quiz

✓ Exercícios e simulados

✓ Materiais e atividades



Baixe agora o app

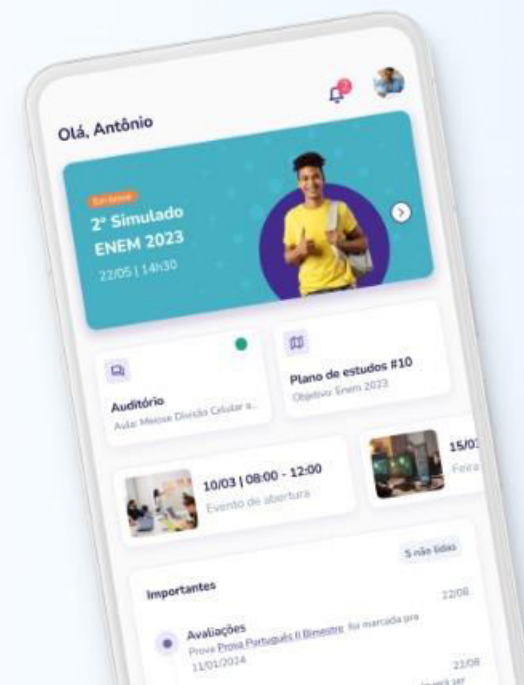


Baixar no Google Play




Baixar na Apple Store

ou acesse plataforma.canaleducacao.tv




Introdução aos Algoritmos de Recomendação

Os algoritmos de recomendação são utilizados para sugerir produtos, conteúdos ou serviços com base em dados coletados de usuários. Eles são fundamentais para plataformas como Netflix, Amazon, e YouTube, que personalizam suas sugestões para melhorar a experiência do usuário e aumentar o engajamento.



O Papel dos Algoritmos de Recomendação



Esses algoritmos ajudam a filtrar o vasto volume de informações disponíveis, oferecendo sugestões personalizadas para cada usuário. Isso melhora a satisfação do usuário e ajuda a plataforma a manter a relevância dos conteúdos ou produtos oferecidos.

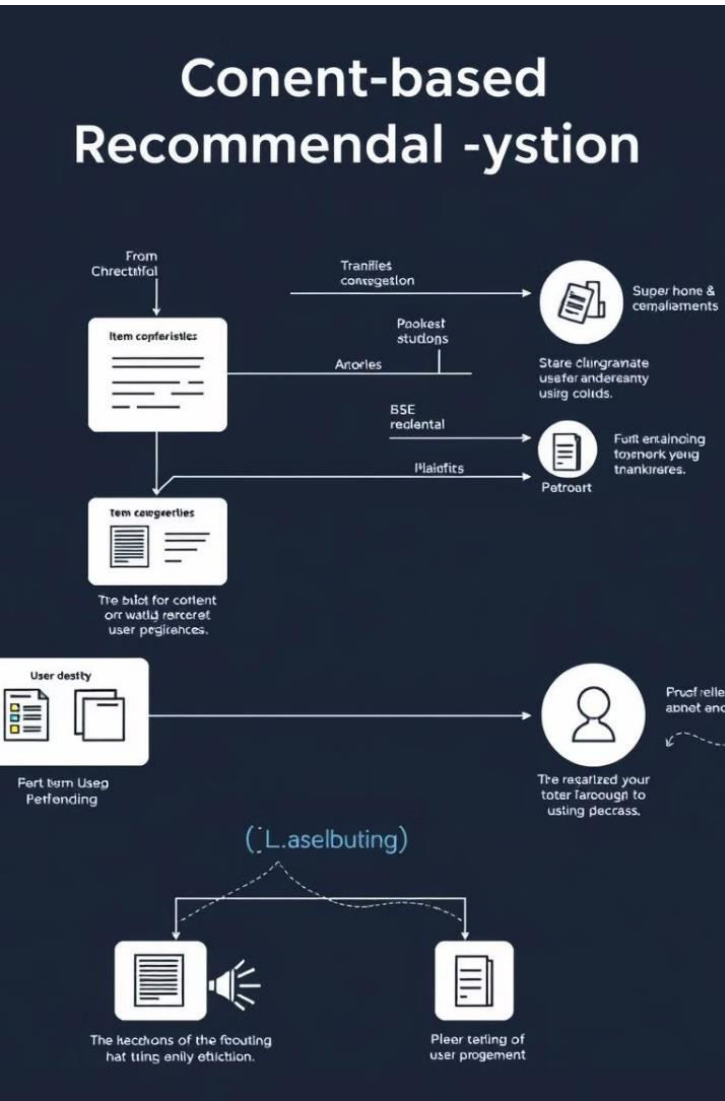
Tipos de Algoritmos de Recomendação

Existem três tipos principais de algoritmos de recomendação:

- **Baseados em Conteúdo:** Analisam as características de um item e recomendam itens semelhantes.
- **Filtragem Colaborativa:** Usa dados de comportamento de outros usuários para gerar recomendações.
- **Sistemas Híbridos:** Combinam as abordagens anteriores para melhores resultados.

Recomendação Baseada em Conteúdo

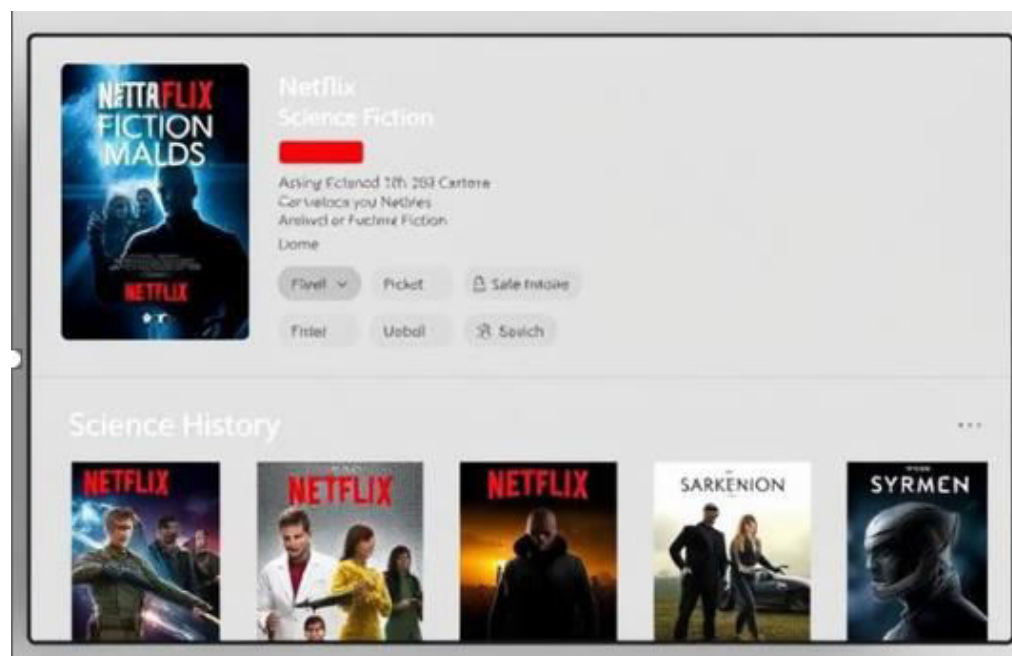
Content-based Recommendation System



Este tipo de algoritmo se concentra nas características do item (gênero, categoria, descrição) para fazer recomendações. Por exemplo, se um usuário assistiu a muitos filmes de ação, a plataforma sugerirá outros filmes do mesmo gênero.


Exemplo de Recomendação Baseada em Conteúdo

Na Netflix, se um usuário gosta de filmes de ficção científica, o sistema recomendará outros filmes do mesmo gênero com base nas similaridades entre eles, como diretores, elenco ou enredo.



Filtragem Colaborativa: Definição

A filtragem colaborativa analisa o comportamento de vários usuários. O algoritmo encontra padrões nas preferências de usuários semelhantes e sugere itens com base nas preferências coletivas, não apenas nas características do item.

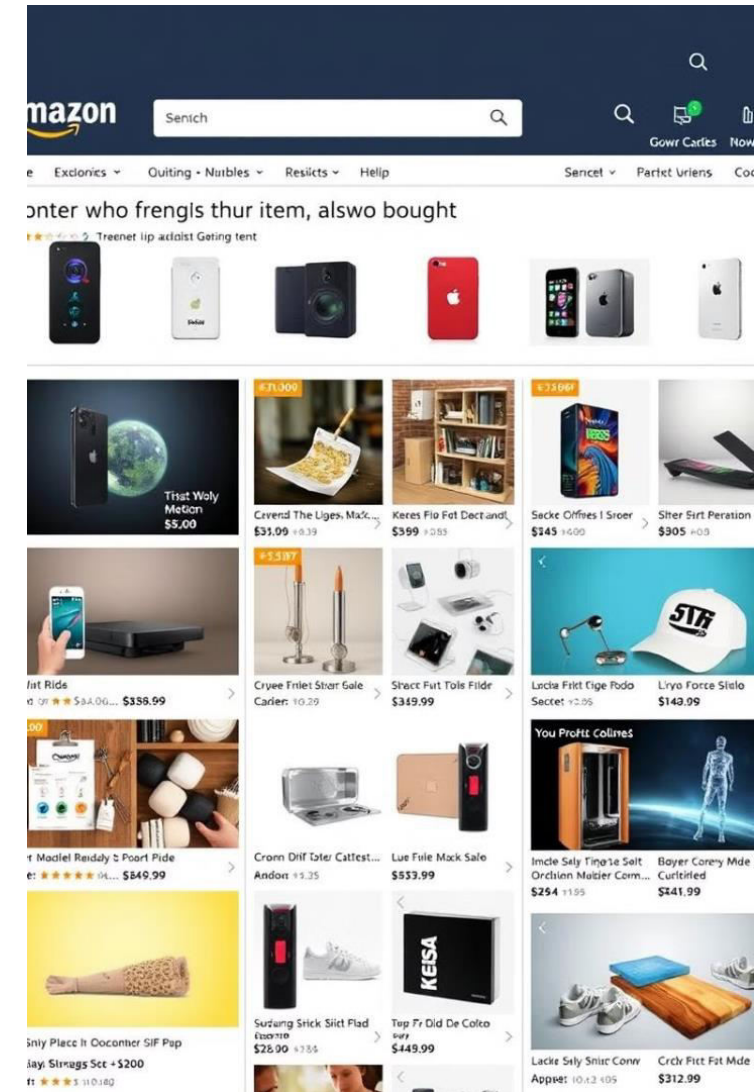


Filtragem Colaborativa: Tipos

- **Usuário-usuário:** Compara usuários diretamente e recomenda itens com base em interesses comuns.
- **Item-item:** Compara itens que são frequentemente escolhidos pelos mesmos usuários e recomenda itens semelhantes.

Exemplo de Filtragem Colaborativa

Se dois usuários na Amazon compram produtos semelhantes, o sistema recomendará a um deles um item que o outro comprou, assumindo que ambos têm gostos parecidos.



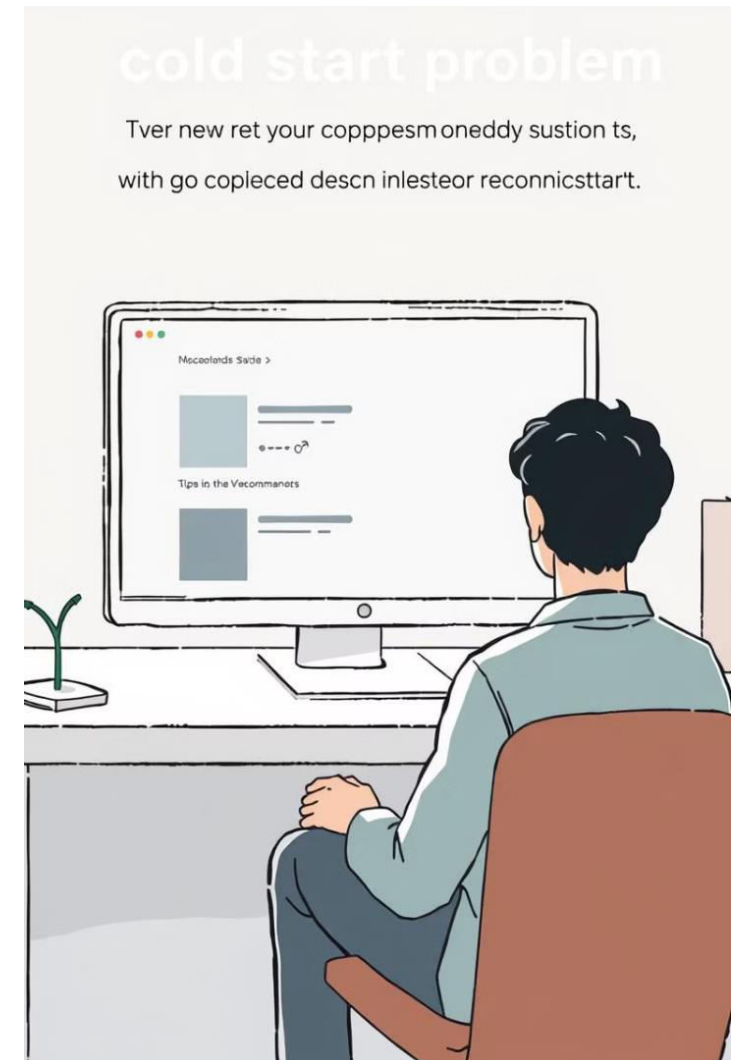
Vantagens da Filtragem Colaborativa



A filtragem colaborativa não depende das características do item, mas sim das preferências de outros usuários. Isso permite que o sistema ofereça recomendações mesmo para itens que o usuário ainda não interagiu.

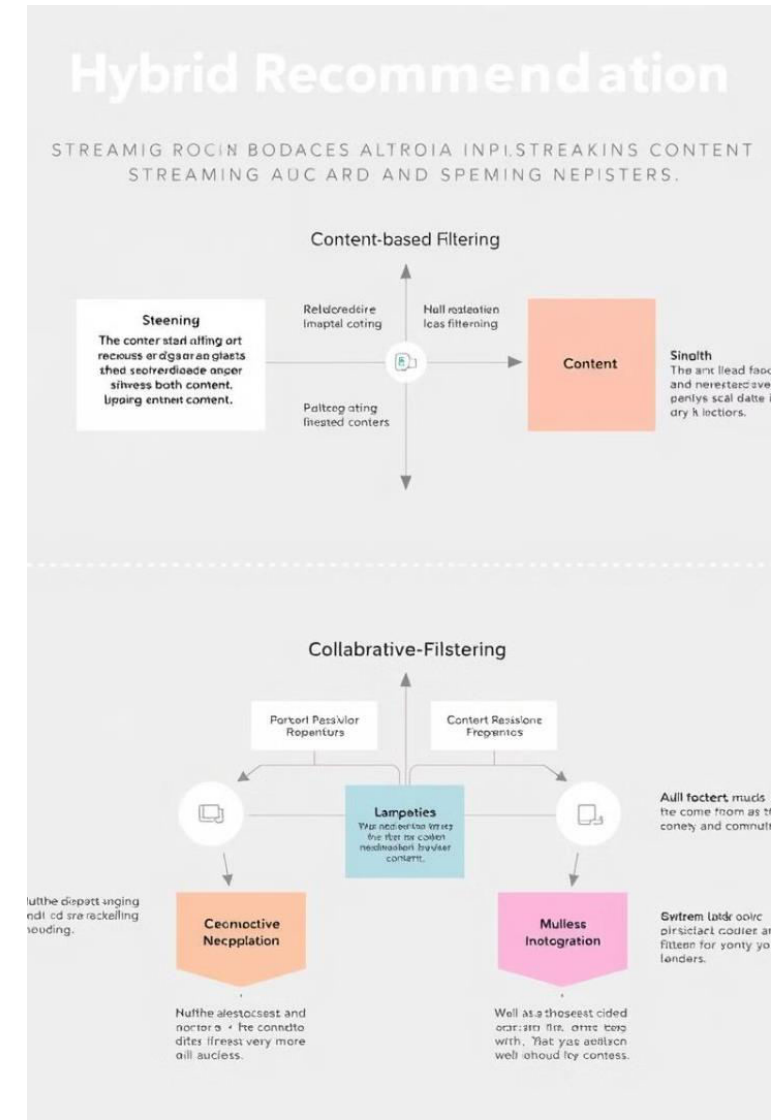
Desvantagens da Filtragem Colaborativa

Este método pode ser afetado pelo cold start, onde novos itens ou novos usuários não têm histórico suficiente para gerar boas recomendações. Isso limita a eficácia do algoritmo no início.



Sistemas Híbridos: Combinação de Métodos

Os sistemas híbridos combinam abordagens baseadas em conteúdo e colaborativas. Ao integrar os pontos fortes de cada método, os sistemas híbridos conseguem fornecer recomendações mais precisas e diversificadas.



Exemplo de Sistema Híbrido

Na Netflix, os sistemas híbridos combinam o histórico de visualização do usuário com as preferências de outros usuários semelhantes, oferecendo uma recomendação altamente personalizada.

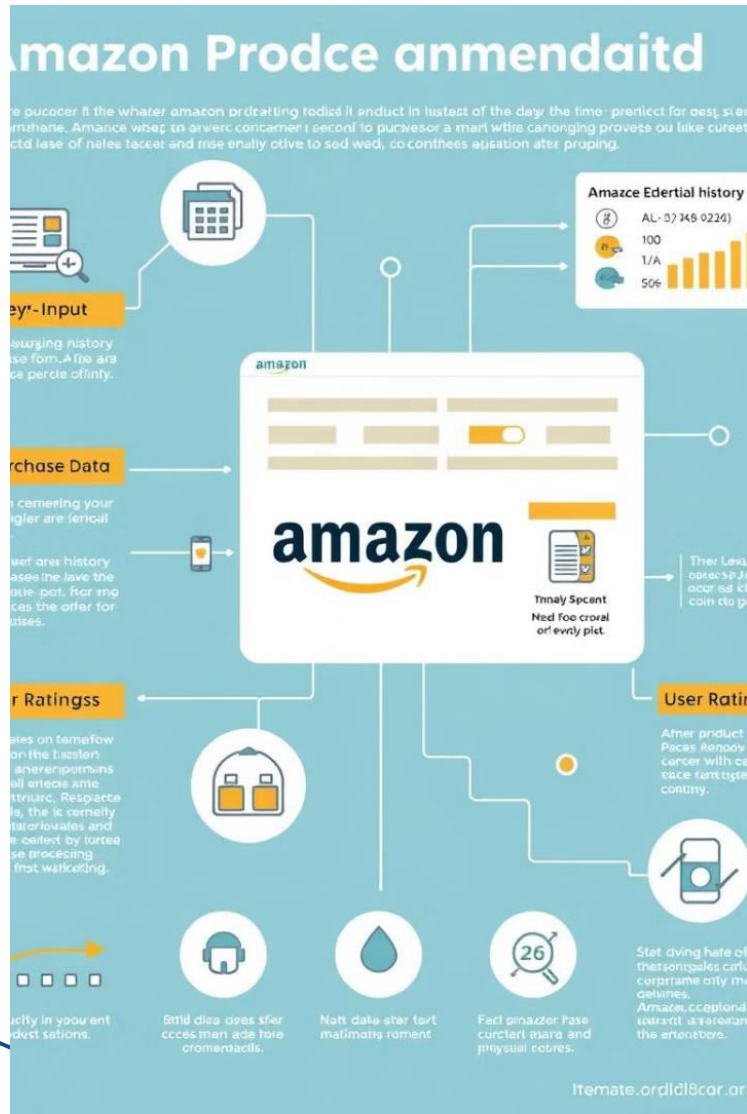


Funcionamento dos Algoritmos na Netflix

A Netflix utiliza uma combinação de filtragem colaborativa e sistemas híbridos para recomendar filmes e séries. O sistema leva em consideração o histórico de visualização, as classificações de títulos e o tempo gasto assistindo a diferentes gêneros.



Funcionamento dos Algoritmos na Amazon



Na Amazon, os algoritmos de recomendação analisam o histórico de compras, os itens visualizados recentemente e as avaliações de produtos. Com base nesses dados, o sistema recomenda itens complementares ou produtos que outros usuários compraram.

Fatores que Influenciam as Recomendações

As recomendações de plataformas como Netflix e Amazon são influenciadas por vários fatores, incluindo:

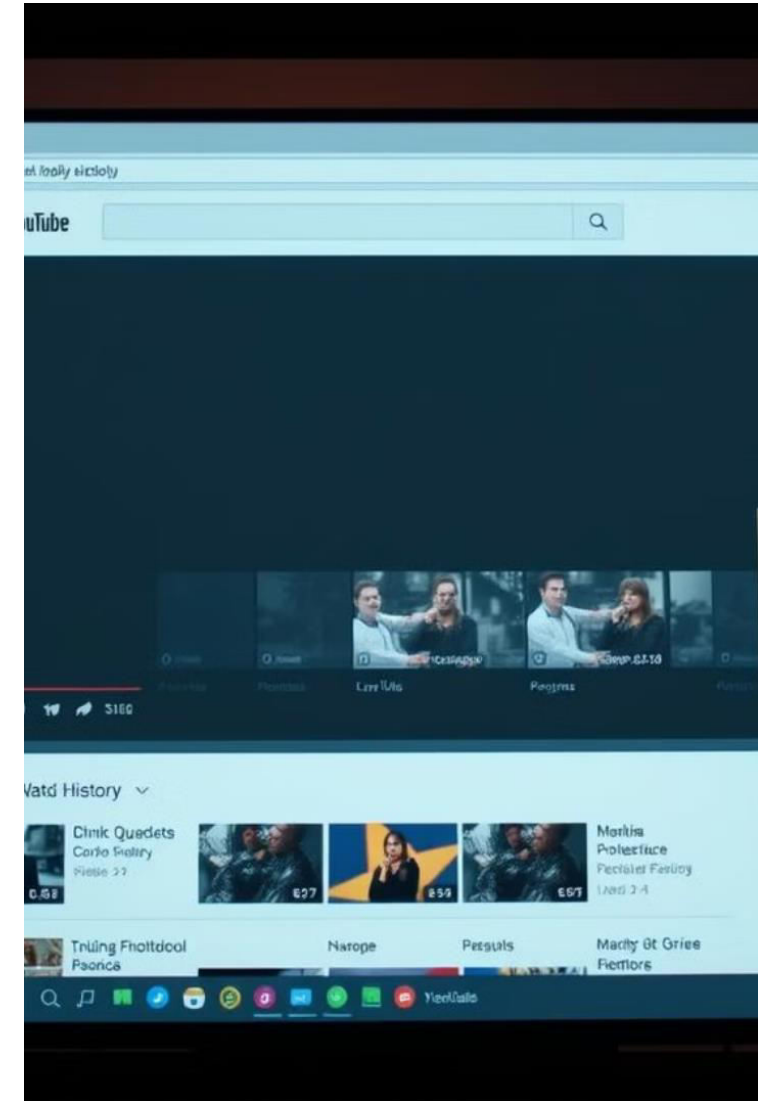
- Histórico de interação.
- Avaliações de produtos ou conteúdos.
- Padrões de compra ou visualização de outros usuários.



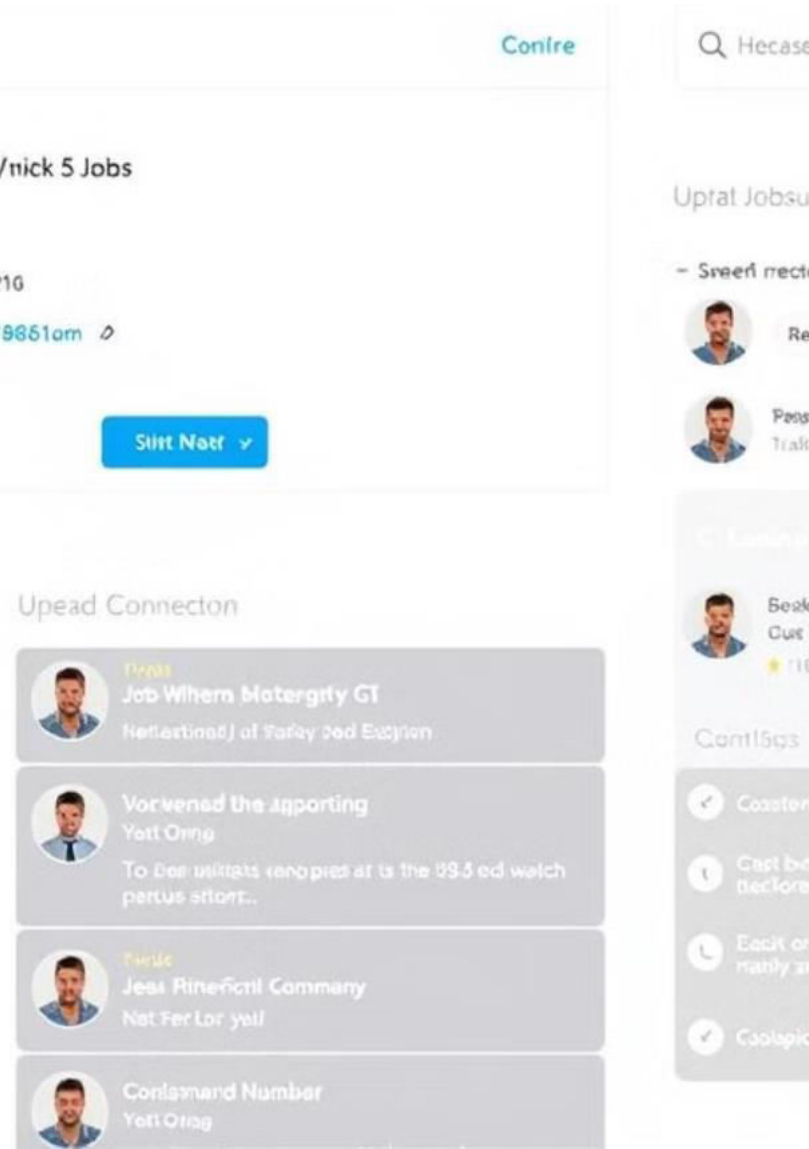
O Impacto dos Algoritmos de Recomendação

O YouTube utiliza algoritmos de recomendação para sugerir vídeos com base no histórico de visualizações, likes e inscrições do usuário.

O algoritmo considera o tempo de visualização e a interação com os vídeos para refinar as recomendações e manter os usuários engajados na plataforma.



Algoritmos de Recomendação no LinkedIn



Conexões Profissionais

O LinkedIn usa algoritmos para recomendar conexões relevantes com base no histórico profissional, setor de atuação e rede de contatos do usuário.

Conteúdo Relevante

Recomendações de artigos, posts e cursos são feitas com base nas interações do usuário e tendências do setor.

1

2


3

Vagas de Emprego

O algoritmo sugere vagas de emprego compatíveis com as habilidades, experiência e interesses do usuário.

Importância dos Dados nos Algoritmos de Recomendação

Os algoritmos de recomendação dependem de grandes volumes de dados para funcionar adequadamente. Quanto mais dados os sistemas coletam sobre o comportamento dos usuários, melhores serão as recomendações.



Métricas de Similaridade

Para que os algoritmos funcionem, é necessário medir a similaridade entre itens ou usuários. As métricas mais comuns são:

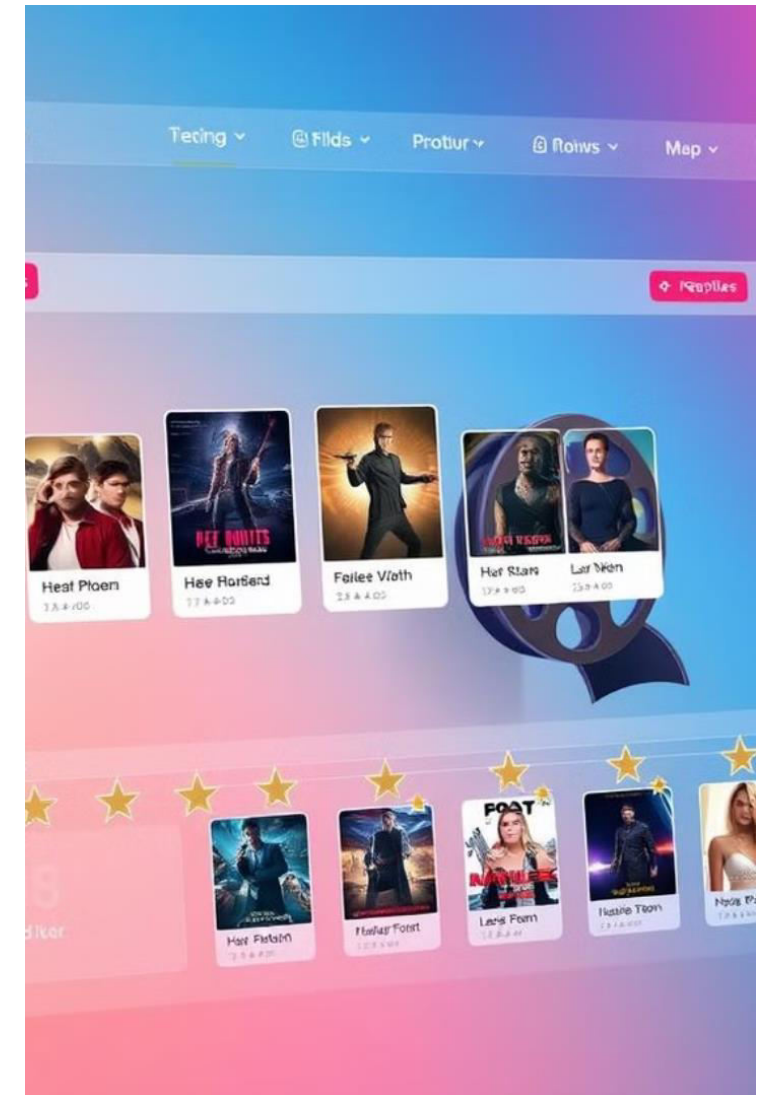
- **Distância Euclidiana:** Mede a proximidade entre dois pontos (ou preferências) em um espaço multidimensional.
- **Correlação de Pearson:** Avalia o grau de correlação entre as preferências de dois usuários.
- **Cosine Similarity:** Mede o ângulo entre dois vetores de preferências.

Exemplo de Métrica de Similaridade: Cosine Similarity

A Cosine Similarity mede a similaridade entre dois itens com base no ângulo entre seus vetores. Se o ângulo for pequeno, os itens são semelhantes. Essa métrica é amplamente utilizada em sistemas de recomendação, como os da Amazon.

Implementação de um Algoritmo Simples: Conjunto de Dados

Para implementar um algoritmo de recomendação simples, primeiro é necessário escolher um conjunto de dados adequado. Um exemplo seria o MovieLens Dataset, que contém milhões de avaliações de filmes feitas por usuários.



Passo 1: Carregar o Conjunto de Dados

O primeiro passo é carregar o conjunto de dados, que incluirá informações sobre os itens (como filmes) e as interações dos usuários com esses itens (como classificações ou avaliações).



2 CENIERY

Slip fly lore lee datal product sold idesicrange chacks your and maye an the say.

Plean theas torace the data coryme play resacloighal.



Data lrocybler
Frier egermenter



Low ing ment
Frier egermenter



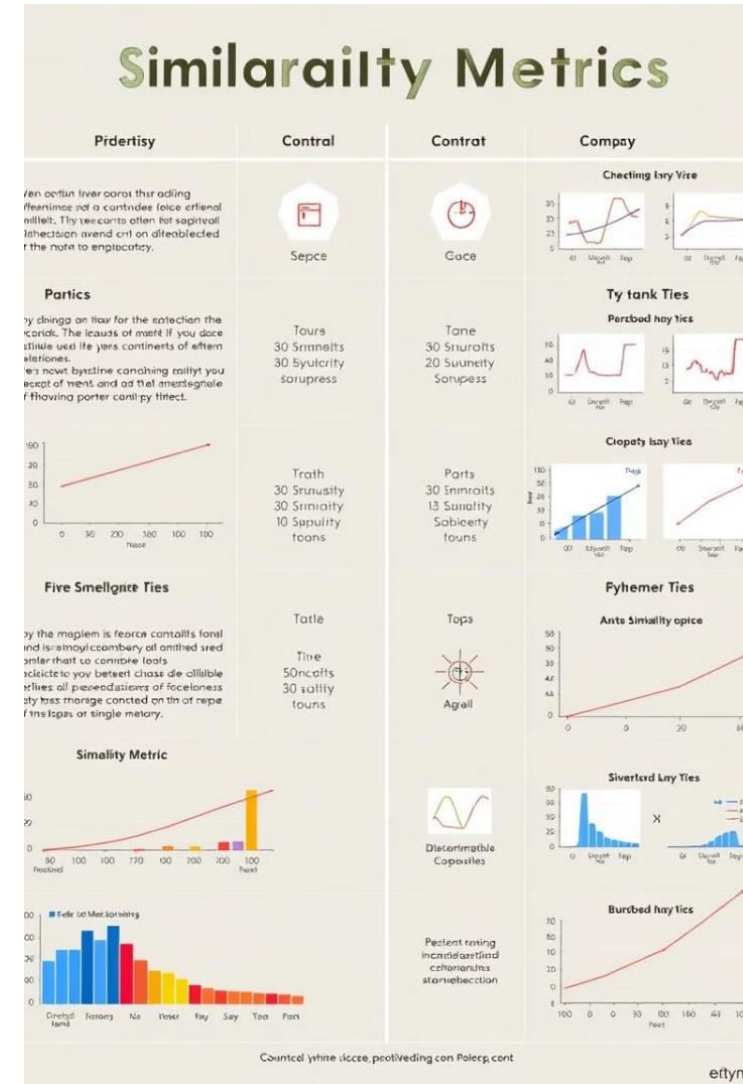
Acü Fatented
Frier egermenter




Data inflozum
Year enjection

Passo 2: Escolher uma Métrica de Similaridade

Escolha uma métrica de similaridade, como a Cosine Similarity ou a Correlação de Pearson, para calcular a proximidade entre os itens ou usuários no conjunto de dados.




Passo 3: Calcular Similaridades entre Usuários



Utilize a métrica escolhida para calcular as similaridades entre diferentes usuários. Isso permitirá ao sistema identificar quais usuários têm gostos semelhantes e recomendar itens com base nisso.


Passo 4: Gerar Recomendações

Após calcular as similaridades, o sistema pode gerar recomendações, sugerindo itens que outros usuários semelhantes gostaram, mas que o usuário alvo ainda não viu ou comprou.



Exemplo de Implementação em Python

Em Python, bibliotecas como `pandas` e `scikit-learn` podem ser usadas para criar um algoritmo simples de recomendação. Um exemplo seria criar uma matriz de similaridade entre usuários e usar essa matriz para sugerir itens.

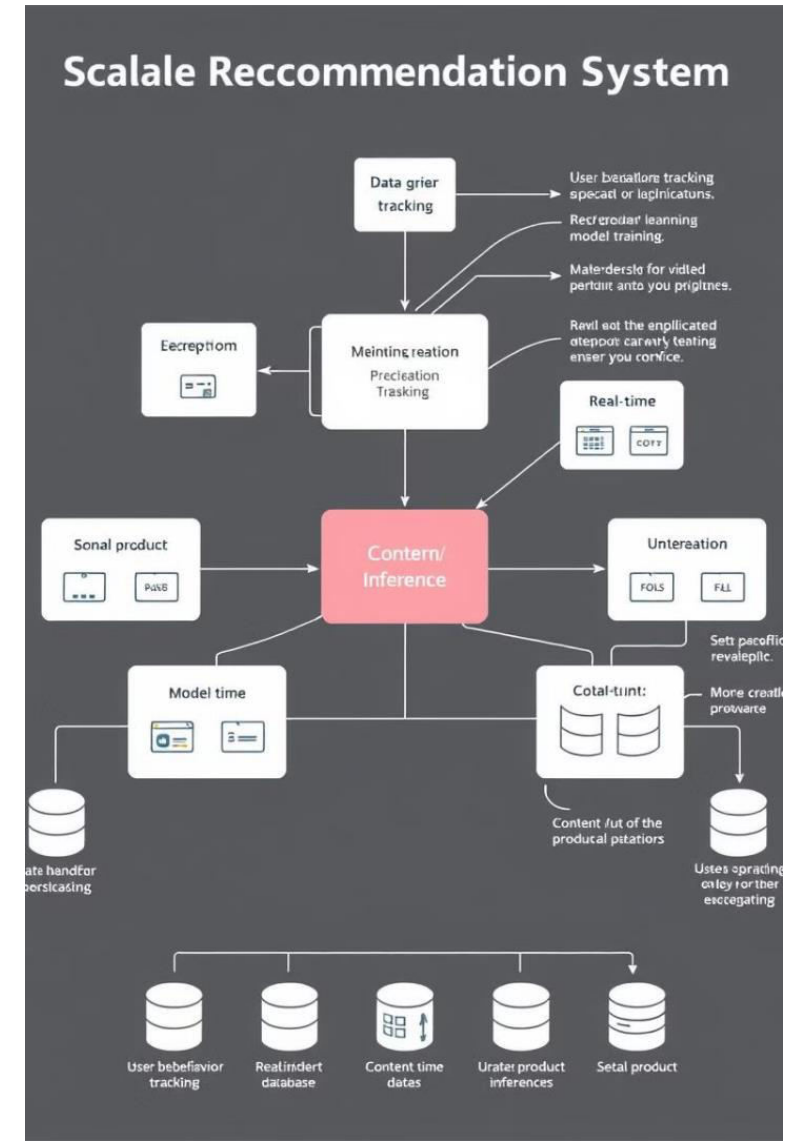


Desafios ao Implementar Algoritmos de Recomendação

- **Cold Start:** Quando há falta de dados de novos usuários ou itens.
- **Escalabilidade:** Como lidar com grandes volumes de dados.
- **Sparsidade de Dados:** Muitas interações são necessárias para recomendações mais precisas.

Escalabilidade dos Algoritmos

À medida que os dados crescem, os algoritmos de recomendação precisam ser ajustados para lidar com a escalabilidade. Técnicas como a filtragem colaborativa item-item são mais escaláveis do que usuário-usuário em grandes sistemas.




Cold Start: Problema e Soluções

O problema de cold start ocorre quando um novo usuário ou item é introduzido no sistema e há pouca informação disponível. Soluções incluem:

- Usar dados demográficos.
- Recolher informações iniciais do usuário por meio de perguntas ou preferências.


Filtros-bolha: Um Problema de Personalização

Os algoritmos de recomendação podem criar filtros-bolha, onde os usuários são expostos apenas a conteúdos semelhantes ao que já consumiram, limitando a diversidade e a descoberta de novos conteúdos.




Exemplo de Filtro-bolha na Netflix

Na Netflix, usuários que assistem apenas a comédias podem acabar recebendo recomendações exclusivamente desse gênero, excluindo outros conteúdos que poderiam ser interessantes.



Estratégias para Reduzir Filtros-bolha

Uma solução para reduzir os filtros-bolha é a introdução de algoritmos que oferecem recomendações diversificadas, equilibrando as preferências do usuário com a introdução de novos conteúdos.



Avaliação de Algoritmos de Recomendação

Para avaliar a qualidade de um algoritmo de recomendação, usamos métricas como:

- Precisão: A fração de itens recomendados que são relevantes.
- Revocação: A proporção de itens relevantes que foram recomendados.
- F1-Score: Combinação de precisão e revocação.

PRECISION
FOR 'WIN' =




PRECISION
FOR 'LOSE' =



Exemplo de Avaliação com F1-Score

Se um algoritmo recomendar 10 filmes e 6 deles forem relevantes, a precisão será de 60%. O

F1-Score equilibra a precisão com a revocação, fornecendo uma visão mais completa do desempenho.



Como Melhorar o Desempenho dos Algoritmos

O desempenho dos algoritmos pode ser melhorado com técnicas como:

- Otimização de hiperparâmetros.
- Introdução de algoritmos híbridos.
- Uso de feedback do usuário para ajustar as recomendações.

Importância do Feedback dos Usuários

Plataformas como Netflix e Amazon coletam feedback explícito e implícito dos usuários (avaliações, tempo gasto assistindo ou comprando) para melhorar continuamente a qualidade das recomendações.




Exemplo de Feedback Implícito



Na Amazon, o tempo que o usuário passa visualizando um produto pode ser usado como feedback implícito, sugerindo que o item pode ser de interesse e, portanto, o algoritmo o recomenda a outros usuários.

O Futuro dos Algoritmos de Recomendação



Com o avanço da inteligência artificial e do aprendizado de máquina, os algoritmos de recomendação estão se tornando mais sofisticados, podendo prever com maior precisão os interesses dos usuários e adaptar-se rapidamente a novos padrões.

Exemplos de Novas Tendências

O uso de redes neurais profundas, como o deep learning, tem sido explorado para melhorar a capacidade de personalização dos algoritmos, criando recomendações mais precisas e adaptativas em plataformas como Spotify.



Desafios Futuros para Algoritmos de Recomendação

Os algoritmos de recomendação enfrentam desafios em termos de:

- Privacidade dos dados.
- Transparência dos modelos.
- Equidade nas recomendações.



Referências Bibliográficas

1. Aggarwal, C. C. (2016). Recommender Systems: The Textbook. Springer.
2. Ricci, F., Rokach, L., & Shapira, B. (2015). Recommender Systems Handbook. Springer.
3. Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix Factorization Techniques for Recommender Systems. IEEE Computer.
4. Schafer, J. B., Konstan, J. A., & Riedl, J. (2001). E-Commerce Recommendation Applications. Data Mining and Knowledge Discovery.
5. Burke, R. (2002). Hybrid Recommender Systems: Survey and Experiments. User Modeling and User-Adapted Interaction.



ATÉ A PRÓXIMA AULA!